

卡方检验 (Chi-square Test) 学习笔记

一、卡方检验的基本概念

卡方检验是一种非参数统计方法，用于分析分类数据（频数数据）之间的差异是否显著。其核心思想是：

通过比较“实际观测频数 (Observed)”与“理论期望频数 (Expected)”之间的差异，判断样本数据是否符合某种假设。

常见的两种类型：

类型	数据形式	检验目的	自由度
拟合优度检验	单变量分类数据	检验样本是否符合某理论分布	$(k - 1 - r)$
独立性检验	二维列联表	检验两个变量是否相互独立	$((r - 1)(c - 1))$

二、卡方拟合优度检验 (Goodness-of-Fit Test)

目的

判断样本是否服从某一理论分布（给定类别概率 p_i ，或连续分布经分组后得到的类别概率）。

假设

- H_0 : 样本服从给定的理论分布；
- H_1 : 样本不服从该分布。

基本公式与分布

设：

- O_i : 第 i 类的观测频数;
- $E_i = np_i$: 第 i 类的期望频数;
- n : 样本总量;
- p_i : 理论分布在第 i 类上的概率, $\sum_i p_i = 1$ 。

统计量

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

在 H_0 成立、且各格 E_i 足够大 (经验: 多数 ≥ 5) 的渐近条件下,

$$\chi^2 \sim \chi^2(k - 1 - r),$$

其中 k 为类别数, r 为从数据里估计的分布参数个数 (若理论概率完全给定, 则 $r = 0$) 。

例: 检验“正态分布”, 若均值、方差都用样本估计, 则 $r = 2$ 。

⚙️ 检验步骤

1. 提出假设 H_0, H_1 。
2. 计算期望频数 $E_i = n p_i$ 。
3. 计算统计量 $\chi^2 = \sum (O_i - E_i)^2 / E_i$ 。
4. 确定自由度 $df = k - 1 - r$ 。
5. 得到 p 值 (右尾) :

$$p = \Pr(\chi_{df}^2 \geq \chi_{obs}^2)$$

或者“查表”拿临界值 $\chi_{\alpha, df}^2$ 。

6. 做结论:
 - 若 $p \leq \alpha$ (或 $\chi_{obs}^2 \geq \chi_{\alpha, df}^2$) , **拒绝** H_0 ;
 - 否则**不拒绝** H_0 。

实务前提: 计数数据、样本独立; 必要时合并稀有类别保证 E_i 不过小。

教学用简例（均匀分布）

问题：4 类是否均匀（每类 $p_i = 0.25$ ）？
观测频数 $O = [18, 32, 27, 23]$ ，总数 $n = 100$ 。
期望频数 $E = [25, 25, 25, 25]$ 。

统计量

$$\chi^2 = \frac{(18 - 25)^2}{25} + \frac{(32 - 25)^2}{25} + \frac{(27 - 25)^2}{25} + \frac{(23 - 25)^2}{25} = 4.24.$$

自由度 $df = k - 1 - r = 4 - 1 - 0 = 3$ 。

p 值（右尾）约 $p = 0.237$ ；也就是 $\chi^2 \sim \chi^2(3) \geq 4.24$ 时候的概率（通过查表得到）
或“查表”： $\chi^2_{0.05,3} = 7.815$ ，而 $4.24 < 7.815$ 。

结论： $p > 0.05$ ，**不拒绝** H_0 （数据与“均匀”不矛盾）。

三、卡方独立性检验（Test of Independence）

目的

检验两个**分类变量**之间是否**相互独立**。

假设

- H_0 ：两个变量相互独立；
- H_1 ：两个变量存在关联。

列联表（Contingency Table）

	B ₁	B ₂	...	B _c	行合计
A ₁	O_{11}	O_{12}	...	O_{1c}	R_1
A ₂	O_{21}	O_{22}	...	O_{2c}	R_2
...	...	...	...	...	...
A _r	O_{r1}	O_{r2}	...	O_{rc}	R_r

	B ₁	B ₂	...	B _c	行合计
列合计	C ₁	C ₂	...	C _c	n

期望频数计算

在 (H₀) (独立性) 假设下:

[

$$E_{ij} = \frac{R_i \times C_j}{n}$$

]

卡方统计量

[

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

]

其中自由度为:

[

$$df = (r - 1)(c - 1)$$

]

检验步骤

1. 构造列联表, 求 (O_{ij})、(R_i)、(C_j)、(n);
2. 计算期望频数 (E_{ij});
3. 计算统计量 (χ²);
4. 查表 (自由度 = ((r - 1)(c - 1)), 显著性水平 (α));
5. 根据临界值判断是否拒绝 (H₀)。

■ 示例

性别	吸烟	不吸烟	合计
男	40	60	100
女	20	80	100
合计	60	140	200

1) 期望频数 E_{ij}

总样本 $n = 200$, 行边际 $R_{\text{男}} = R_{\text{女}} = 100$, 列边际 $C_{\text{吸}} = 60$, $C_{\text{不吸}} = 140$ 。

$$\begin{aligned} E_{\text{男,吸}} &= \frac{100 \cdot 60}{200} = 30, & E_{\text{男,不吸}} &= \frac{100 \cdot 140}{200} = 70, \\ E_{\text{女,吸}} &= \frac{100 \cdot 60}{200} = 30, & E_{\text{女,不吸}} &= \frac{100 \cdot 140}{200} = 70. \end{aligned}$$

2) Pearson 卡方统计量

$$\chi^2 = \sum \frac{(O - E)^2}{E} = \frac{(40 - 30)^2}{30} + \frac{(60 - 70)^2}{70} + \frac{(20 - 30)^2}{30} + \frac{(80 - 70)^2}{70} \approx 9.524.$$

自由度 $df = (2 - 1)(2 - 1) = 1$ 。

p 值 (右尾) : $p \approx 0.002$ (显著) 。也就是 $\chi^2 \sim \chi^2(1) \geq 9.524$ 时候的概率 (通过查表得到)

3) 结论

- 在 $\alpha = 0.05$ 下: $p < 0.05 \rightarrow$ **拒绝独立性假设 H_0** , 认为“性别”与“吸烟”**存在关联**。
 - 若用临界值法: $\chi_{0.05, 1}^2 = 3.841$, 而 $9.524 > 3.841$ (同样拒绝 H_0) 。
 - $p < 0.05 \rightarrow$ 拒绝独立性假设, 认为变量有关;
 - $p \geq 0.05 \rightarrow$ 接受独立性假设, 认为变量独立。
-

总结对比

项目	拟合优度检验	独立性检验
目的	检验样本是否服从指定分布	检验两个分类变量是否独立
数据类型	单变量	双变量
统计量	$(\sum(O_i - E_i)^2 / E_i)$	$(\sum(O_{ij} - E_{ij})^2 / E_{ij})$
自由度	$(k - r - 1)$	$((r - 1)(c - 1))$
前提条件	$(E_i \geq 5)$	$(E_{ij} \geq 5)$