

《数据科学》实验报告

班级	003	姓名	史润	学号	20241220
实验题目	数据预处理				
实验时间	2025-10-18	实验地点	DS1408		
学年学期	2025-2026(1)	实验性质	☐ 验证性 ☐ 设计性 ☒ 综合性		

代码：

```
"""1. 利用 pandas 工具包将数据 1 和数据 2 中的数据载入并进行合并，查看合并后的 dataframe 的前 5 行。
提示：
① concat 和 append 可以实现的是表间“拼接”，而 merge 和 join 则实现的是表间“合并”，区别在于是否基于”键“来进行合并。如果只是简单地”堆砌“，则用 concat 和 append 比较合适，而如果遇到关联表，需要根据”键“来合并，则用 merge 和 join。
② concat 和 merge 是 pandas 的属性，所以调用的时候应该写成 pd.concat() 或者 pd.merge(); 而 append 和 join 是对 DataFrame 的方法，所以调用的时候应该写成 df.append()或者 df.join()。"""
import pandas as pd

df1 = pd.read_csv(r"C:\数据科学_Py\实验 4\数据 1.csv", encoding="ANSI")
df2 = pd.read_excel(r"C:\数据科学_Py\实验 4\数据 2.xlsx")
df = pd.concat([df1, df2])
print(df.head())

输出：
   中文名  外文名  性别  国籍  身高  体重  项目  省份
0  安-弗雷泽  Shelly-Ann Fraser-Pryce  女  牙买加  160厘米  52kg  田径  NaN
1  安吉尔·麦克康特利  Angel McCoughtry  女  美国  185cm  73kg  篮球  NaN
2  毕晓琳  Bi Xiaolin  女  中国  NaN  NaN  足球  辽宁
3  阿莱克斯·加西亚  Alex Garcia  男  巴西  191厘米  89kg  篮球  NaN
4  保罗·乔治  Paul George  男  美国  203厘米  95kg  篮球  NaN

# 2. 对合并后的数据进行筛选，保留国籍为中国的女篮运动员数据。
df = df[(df["国籍"] == "中国") & (df["性别"] == "女") & (df["项目"] == "篮球")]

# 3. 对筛选后的数据进行清理：
# 3.1 首先对重复的行进行删除；（提示：注意字符串中的空格）
df = df.drop_duplicates(subset=["外文名"]) # 因为中文名会存在空格，所以用外文名去重
"""3.2 随后对异常值的替换，包括：
① 将身高列数据修正，使用平均值填充空值，统一为数字格式，保留一位小数，并将列名从“身高”重命名为“身高/cm”；
② 体重列单位统一为“kg”，处理明显的错误数据，用平均值填充空值。
③ 最后将省份的空缺值修改为“未知”，使用“loc”的索引方法修改“陈楠”的“省份”为“青岛”，使用“iloc”的索引方法修改“陈晓佳”的“省份”为“江苏”。"""
cor = {
```

```

    "191cm": "191 厘米",
    "1 米 89 公分": "189 厘米",
    "2.01 米": "201 厘米",
    "187 公分": "187 厘米",
    "192cm": "192 厘米",
    "1.98 米": "198 厘米",
}
df.loc[:, "身高"] = df.loc[:, "身高"].replace(cor)
i = 0
for x in df.loc[:, "身高"]:
    if pd.isna(x):
        pass
    else:
        df.iloc[i, 4] = int(x[:-2])
        i += 1
df.loc[:, "身高"] = df.loc[:, "身高"].fillna(df.loc[:, "身高"].mean())
df.loc[:, "身高"] = df.loc[:, "身高"].map(lambda x: f"{x:.1f}")
df.rename(columns={"身高": "身高/cm"}, inplace=True)

df.loc[:, "体重"] = df.loc[:, "体重"].replace({"88 千克": "88kg"})
df["体重"].replace("8kg", method="pad", inplace=True)
w = df["体重"].dropna()
w_m = w.apply(lambda x: x[:-2]).astype(int).mean()
str_w = f"{w_m:.0f}kg"
df.loc[:, "体重"] = df.loc[:, "体重"].fillna(str_w)

df.loc[:, "省份"] = df.loc[:, "省份"].fillna("未知")
df.loc[23, "省份"] = "青岛"
df.iloc[6, 7] = "江苏"
print(df)
输出:

```

	中文名	外文名	性别	国籍	身高/cm	体重	项目	省份
77	邵婷	Shao Ting	女	中国	188.0	75kg	篮球	上海
119	孙梦然	Sun Meng Ran	女	中国	197.0	77kg	篮球	天津
121	孙梦昕	Sun Meng Xin	女	中国	190.0	77kg	篮球	山东
159	吴迪	Wu Di	女	中国	186.0	72kg	篮球	天津
301	赵志芳	Zhao Zhi Fang	女	中国	168.0	80kg	篮球	未知
23	陈楠	Chen Nan	女	中国	197.0	90kg	篮球	青岛
27	陈晓佳	Chen Xiao Jia	女	中国	180.0	70kg	篮球	江苏
57	李梦	Li Meng	女	中国	189.3	76kg	篮球	辽宁
58	高颂	Gao Song	女	中国	191.0	85kg	篮球	黑龙江
59	潘臻琦	Pan Zhen Qi	女	中国	191.0	82kg	篮球	河南
60	张茹	Zhang Ru	女	中国	189.0	80kg	篮球	河南
61	李月汝	Li Yue Ru	女	中国	201.0	103kg	篮球	山西
62	郭子瑄	Guo Zi Xuan	女	中国	187.0	80kg	篮球	河北
64	黄思静	Huang Si Jing	女	中国	192.0	80kg	篮球	广东
65	张丽婷	Zhang Li Ting	女	中国	198.0	88kg	篮球	湖北
115	黄红杞	Huang Hong Pi	女	中国	195.0	80kg	篮球	广西南宁
176	李珊珊	Li Shan Shan	女	中国	177.0	70kg	篮球	江苏
227	露雯	Lu Wen	女	中国	191.0	78kg	篮球	内蒙古鄂尔多斯

"""4. 计算女篮运动员的身高数据的中位数、众数、标准差；找出身高在前 25%的运动员，将姓名导出为 txt 文档；在同一个 figure 的左右两边分别绘制女篮运动员的身高数据的箱型图和直方图。"""


```
df_h = df["身高/cm"].apply(lambda x: float(x))
```

```
print(df_h.median())
print(df_h.mode())
print(df_h.std(axis=0))
name = df_h[df_h["身高/cm"] >= df_h["身高/cm"].quantile(0.75)]
df[name].to_csv("导出.txt", index=False)
import matplotlib.pyplot as plt
```

```
figure, ax = plt.subplots(1, 2)
df_h = pd.DataFrame(df_h)
df_h.boxplot(column="身高/cm", ax=ax[0])
plt.ylabel("cm")
plt.subplot(1, 2, 1)
df_h.hist(column="身高/cm", ax=ax[1])
plt.rcParams["font.sans-serif"] = ["SimHei"]
plt.rcParams["axes.unicode_minus"] = False
plt.show()
```

输出:

```
190.5
0    191.0
Name: 身高/cm, dtype: float64
8.005620982800863
```



"""5. 设计一个程序，统计 txt 文件中包含的行数和字数；利用程序统计上题导出的姓名文档"""

```
def statistic(file):
    f = open(file, "r", encoding="utf-8")
    count1 = 0
    count2 = 0
    for line in f:
        if line != " ":
            count1 += 1
            print(line)
        for i in line:
            if i != "\n":
                count2 += 1
```

```
print(count1, count2)
return count1, count2
```

```
statistic("导出.txt")
```

输出:

中文名	
孙梦然	张丽婷
陈楠	黄红枇
李月汝	6 20